

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ

**Федеральное государственное автономное
образовательное учреждение высшего образования**

**Национальный исследовательский университет
«Высшая школа экономики»**

Факультет экономических наук
Образовательная программа «Экономика»

КУРСОВАЯ РАБОТА

На тему «Вариация алгоритма кросс-валидации со взвешиванием наблюдений»

Студент группы БЭК161
Гармидер Петр Александрович

Научный руководитель:
Борис Демешев

Москва 2019

Содержание

1	Введение	3
1.1	Параметры и гиперпараметры модели	3
1.2	Типы кросс-валидации	3
1.3	Кросс-валидация для временных рядов	6
2	Взвешенная кросс-валидация для временных рядов	8
2.1	Мотивация	8
2.2	Описание алгоритма	9
2.3	Метод тестирования подхода	10
3	Заключение	11

1 Введение

1.1 Параметры и гиперпараметры модели

Большая часть популярных моделей имеют множество параметров и гиперпараметров однозначно выделяющие модель из множества всех алгоритмов. Гиперпараметры модели — параметры, вводимые пользователем вручную, которые в большинстве случаев не меняются в ходе обучения¹. Параметры модели — параметры, которые не вводятся пользователем вручную, а есть результат оптимизации функции потерь. Их конечные значения становятся известны после завершения процесса обучения. Параметры модели связывают имеющиеся у исследователя данные и выбранный алгоритм для обучения.

Рассмотрим пример. Пусть имеем обучающую выборку $D = \{x_i, y_i\}$ и тестовую выборку $d = \{x_i, y_i\}$, где $x_i, y_i \in R$, $|D| = N$ и $|d| = n$. Будем оценивать y_i используя L_2 - регуляризатор или Ridge-regression (см. [2]). Имеем безусловную задачу оптимизации:

$$\sum_{i=1}^N (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 + \lambda \hat{\beta}_1^2 \rightarrow \min_{\hat{\beta}_0, \hat{\beta}_1} \quad (1)$$

В (1) существуют два параметра для оптимизации $\hat{\beta}_0$ и $\hat{\beta}_1$, а также один гиперпараметр λ , который является константой в рассматриваемой задаче. Коэффициенты регрессии находятся из задачи минимизации при заданном уровне λ , в то время, как степень регуляризации λ задается исследователем. В конечном счете исследователь заинтересован в создании модели, которая имеет высокое качество на тестовой выборке d , что не участвовала в процессе обучения. Качество работы модели на выборке d очевидно зависит от выбранного исследователем λ . Поэтому, выбор оптимального значения для гиперпараметров является также важной задачей для получения лучшей модели.

Гиперпараметрами модели также могут быть: метод обработки пропусков в данных, количество слоев в нейронной сети, выбранные функции активации, уровень Dropout, скорость обучения и другие.

Влияние гиперпараметров на качество работы модели делает их правильный выбор отдельной задачей. Оптимальный алгоритм подбора гиперпараметров уникален для каждой конкретной задачи. Качество работы модели в целом принято оценивать на выборках не участвовавших в обучении, но для которых известно истинное значение зависимой переменной.

1.2 Типы кросс-валидации

Кросс-валидация — техника валидации модели для оценки качества её работы и установления факта обобщающей способности. Метод CV позволяет понять, выучила ли модель зависимость между рассматриваемыми переменными или же алгоритм переобучился и хорошо предсказывает

¹Однако такая практика также используется, например, изменение гиперпараметра learning rate в ходе алгоритма градиентного спуска (см. [1])

лишь данные имеющиеся в обучающей выборке². Как правило, кросс-валидационной проверке подвергаются модели, которые направлены на точность предсказаний, оставляя за бортом вопрос интерпретации полученных результатов.

Разберем некоторые варианты алгоритма кросс-валидации:

Пусть имеем: X — множество признаков, описывающих объекты; Y — множество зависимых переменных; $D^l = \{x_i, y_i\}$ — наблюдаемая выборка, где $x_i \in X$, $y_i \in Y$, l — размер выборки; $Q : (A \times (X \times Y)) \rightarrow R$ — функция потерь; A — модель; $\mu : (X \times Y) \rightarrow A$ — алгоритм обучения [3].

- Валидация на отложенных данных (Hold-out)

Исследователь выбирает число t — количество объектов из множества D , которые будут использованы для обучения модели. Соответственно, оставшая часть объектов $l - t$ используется для проверки качества работы модели. Итого, получаются две выборки $Train^t$ и $Test^{l-t}$ такие, что $Tr^t \cup T^{l-t} = D^l$. Решается задача:

$$HOCV(\mu, Tr^t, T^{l-t}) = Q(\mu(Tr^t), T^{l-t}) \rightarrow \min_{\mu}$$

Tr^t	T^{l-t}
--------	-----------

Рис. 1: Иллюстрация валидации на отложенных данных

Метод Hold-out CV обычно используется в том случае, если исследователь обладает большой обучающей выборкой, т.к. данный способ не требует больших вычислительных мощностей. Итоговое качество Q также зависит от разбиения обучающей выборки, что является главным недостатком метода.

- K-fold кросс-валидация

Исходная выборка D разбивается случайным образом на K непересекающихся, примерно равных по мощности множеств: D_1, D_2, \dots, D_k ; $|D_i| \approx \frac{l}{k}$. После чего, для каждого из получившихся множеств проводится процедура hold-out CV; результаты всех процедур усредняются. Решается задача:

$$KFCV(\mu, D, K) = \frac{1}{K} \sum_{i=1}^K OFCV(\mu(D \setminus D_i), D_i) \rightarrow \min_{\mu}$$

Метод K-fold CV решает проблему высокой зависимости получаемого результата от разбиения, однако является весьма затратным с точки зрения вычислительных мощностей.

Обычно используется в тех случаях, когда размеры выборки и модель позволяют быстро

²В английской литературе данную ситуацию называют overfitting




Рис. 2: Иллюстрация K-fold кросс-валидации при $K = 4$

проводить процедуру обучения. Число K выбирается исследователем на своё усмотрение. Заметим, что при $t = \frac{l}{2}$ Hold-out CV \equiv two-fold CV.

- Leave-one-out кросс-валидация

Частный случай K-fold кросс-валидации, при $K = l$. Исходное множество D разбивается на l подмножеств: D_1, D_2, \dots, D_l ; $|D_i| = 1$. После чего проводится стандартная K-fold кросс-валидация. LOO CV подвергается критике; в некоторых исследованиях говорится, что данный метод плохо оценивает предсказательную силу модели [4]. Кроме того, данный метод требует высоких вычислительных мощностей, т.к. потребуется l раз обучать модель.

- Полная кросс-валидация (Complete)

Исследователь выбирает число t , после чего изначальная выборка D^l разбивается всеми возможными способами на выборки Tr^l и Tt^{l-t} . Заметим, что число возможных разбиений для заданного t равно C_l^{l-t} . Таким образом, исследователь решает задачу:

$$CCV(D, t) = \frac{1}{C_l^{l-t}} \sum_{D^l = Tr^l \cup Tt^{l-t}} Q(\mu(Tr^t), Tt^{l-t}) \rightarrow \min_{\mu}$$

Даже при достаточно небольших значениях t , данный метод проверки работоспособности модели используется крайне редко в силу его вычислительной сложности.

- Случайные разбиения (Random sampling)

Выборка разбивается в случайной пропорции, после чего для получившегося разбиения проводится hold-out CV. Данная процедура повторяется несколько раз; результаты усредняются.

- $M \times K$ -fold кросс-валидация

K-fold кросс-валидация проводится M раз; результаты M валидаций усредняются. Итого:

$$MKFCV(\mu, D, K, M) = \frac{1}{M} \sum_{i=1}^M KFCV(\mu, D, K) \rightarrow \min_{\mu}$$

Метод допустим к использованию при небольшой выборке и алгоритме, который способен обучаться $M \times K$ раз за разумное время.

Одной из причин использования кросс-валидации является подбор гиперпараметров. Допустим исследователь решает задачу по выбору оптимального параметра λ для L_2 - регуляризатора на странице 3. Если не проводить кросс-валидацию, то лучшее качество на выборке D даст модель с $\lambda = 0$, т.к в этом случае на коэффициенты регрессии не накладываются никакие ограничения, а поэтому они сойдутся к решению, которое минимизирует среднеквадратичную ошибку на выборке D . Однако, получаемое качество работы модели на обучающей выборке не отображает реальную картину. Исследователь, в конечном счете, заинтересован создать модель, которая будет иметь высокое качество на объектах не входящих в обучающую выборку. Для этого, есть смысл проверять качество работы модели используя один из перечисленных методов кросс-валидации. В этом случае, оптимальное значение λ скорее всего окажется больше нуля.

1.3 Кросс-валидация для временных рядов

Временной ряд — наблюдаемая выборка данных, объекты которой представлены во временном порядке. В большинстве случаев, временной ряд представлен точками, которые одинаково отдалены друг от друга во временной шкале. Анализ временных рядов значимо отличается от подходов работы с простой выборкой данных: учитывается зависимость точек от времени, а также взаимосвязь текущего значения параметра с лагированными. Примерами временных рядов являются: курс доллар к евро, реальный уровень ВВП США, ключевая ставка ЦБ РФ, последовательность кадров в видеоролике³ и так далее. В данной работе фокус будет сделан на одномерных временных рядах, прогноз для которых будет иметь вид некоторой функции от прошлых значений.

Как и раньше, задача построения моделей для прогнозирования временных рядов включает в себя стадию подбора оптимальных гиперпараметров модели. Однако, по очевидным причинам большинство методов кросс-валидации из секции 1.2 не подходят для случая, когда объектом исследования является временной ряд. Непрактично оценивать модель на случайно выбранных данных, которые с большой долей вероятности потеряют временную структуру при разбиениях.

Очевидным решением в таком случае является разбиение исходной выборки на две части: обучающую и валидационную — с сохранением временной структуры. После чего на последней измерять качество работы модели. Тем не менее, проблема высокой зависимости результата от разбиения становится вновь актуальной. Возможно, исследователь столкнется с ситуацией, когда

³Объектами в таком случае являются трехмерные матрицы, хранящие в себе значения, характеризующее интенсивность RGB каналов

качественная модель плохо справляется лишь с отведенным для валидации блоком данных, но будет давать прогнозы с высокой точностью в долгосрочной перспективе.

Решением данной проблемы является адаптированный алгоритм K-fold кросс-валидации для временных рядов (K-fold TSCV):

Пусть $TS = \{y_t\}$ — наблюдаемая выборка временного ряда, где $|TS| = T$, $t = 1, 2, \dots, T$; $\lambda \in \Lambda$, где Λ — множество всех доступных гиперпараметров для модели μ . Исследователь выбирает число K , после чего TS делится на K блоков: TS_1, TS_2, \dots, TS_K ; $|TS_i| \approx \frac{T}{K}$; $TS_i = \{y_j, y_{j+1}, y_{j+2} \dots\}$. Затем, выбранная модель μ обучается $K - 1$ раз следующим образом: обучение проходит на TS_1 — качество проверяется на TS_2 , обучение проходит на $TS_1 \cup TS_2$ — качество проверяется на TS_3 и так далее. Для подбора оптимального гиперпараметра λ для модели μ исследователь решает задачу:

$$TSCV_K = \frac{1}{K-1} \sum_{i=1}^{K-1} Q(\mu(TS_1 \cup \dots \cup TS_i, \lambda), TS_{i+1}) \rightarrow \min_{\lambda \in \Lambda} \quad (2)$$

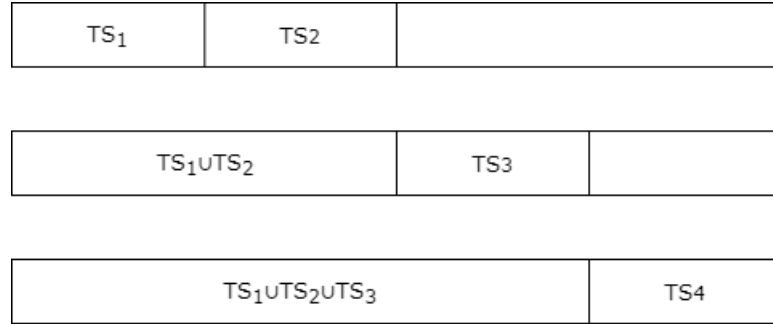


Рис. 3: Иллюстрация K-fold кросс-валидации для временных рядов при $K = 4$

Описанный подход также не является идеальным решением и плохо работает в случаях, когда наблюдений не так много, а следовательно, алгоритму на первых итерациях предстоит обучаться на малом количестве наблюдений и измерять качество на такой же по количеству выборке. Очевидно, что в таких ситуациях модель покажет низкое качество, но это не значит, что она не применима для качественного прогнозирования рассматриваемого ряда.

2 Взвешенная кросс-валидация для временных рядов

2.1 Мотивация

Зависимость временного ряда во времени делает его весьма интересным объектом для изучения. Как правило, рассматриваемые в прикладных задачах ряды являются объектами человеческой деятельности: продажи товаров, количество новых клиентов, — что по определению делает такие ряды подверженными внешним шокам. Хотелось бы подобрать такой алгоритм, который устойчив к данным изменениям и способен хорошо предсказывать будущие значения по всей имеющейся информации на сегодняшний день. В некоторой степени данную задачу может разрешить алгоритм ETS с аккуратно подобранными гиперпараметрами. Ввиду особенностей своей работы ETS позволяет моделировать, например, изменение долгосрочного уровня в ответ на произошедшие в прошлом шоки. Однако, дабы такая модель была решением задачи поиска оптимального алгоритма на кросс-валидации для временных рядов, ETS также должна хорошо предсказывать прошлые данные в то время, когда исследователя, как правило, интересуют актуальные наблюдения. Данные рассуждения наталкивают на идею модификации алгоритма кросс-валидации для устранения упомянутой проблемы.




Рис. 4: Месячный форвардный курс золота (GOFO), в процентах [5]

Чтобы показать, что ситуация описанная выше не является теоретизированной, рассмотрим рис. 4. На данном графике изображен месячный форвардный курс золота в процентах от текущей стоимости за период с 1990 по начало 2015 года. Довольно очевидно, учитывая имеющиеся данные за последние 8 лет, что сильным и, возможно, наилучшим прогнозом для рассматриваемого ряда на ближайшее время будет векторов скаляров в окрестности нуля. Однако, маловероятно, что такая модель будет отобрана на кросс-валидации, учитывая поведение ряда до 2009 года. Видно, что ряд имел участки, где присутствуют: линейно-возрастающий тренд; линейно-убывающим тренд; ярковыраженная сезонность и другие особенности, которые не свойственны

актуальным наблюдениям. Некоторый класс моделей справляются и с такими особенностями ряда. Однако, хотелось бы адаптировать процесс кросс-валидации так, чтобы практически любая модель имела устойчивость к изменчивости характеристик временного ряда, при процессе подбора гиперпараметров

2.2 Описание алгоритма

Основная идея за предлагаемым алгоритмом заключается в вере о том, что модель, которая качественно предсказывает последние наблюдения лучше той, что хорошо работает лишь на давних участках данных. Действительно, часто исследователя вовсе не волнует ситуация, когда модель совершенно не справляется с давними участками, если алгоритм показывает высокое качество на актуальных. Данный факт обуславливается тем, что временные ряды зачастую используются для принятия решений в данный момент времени, основываясь на мнении о том, что будет завтра. Поэтому для пользователя важно иметь высокое качество в прогнозах именно на завтра⁴.

Отсюда вытекает обобщение существующего алгоритма кросс-валидации. Предлагается учитывать качество работы модели на недавних участках с большим весом, а качество работы модели в далеком прошлом с меньшим или не учитывать вовсе. Формально задача сводится к следующей:

Пусть $TS = \{y_t\}$ — наблюдаемая выборка временного ряда, где $|TS| = T$, $t = 1, 2, \dots, T$; $n(y)$ — номер наблюдения y : $n(y_i) = i$; $Q(a, b)$ — некоторая функция, измеряющая различие a и b ; $\mu(\lambda)$ — алгоритм прогнозирования; $\lambda \in \Lambda$, где Λ — множество всех доступных гиперпараметров для μ . Проводим стандартную K-fold кросс-валидацию для временных рядов (2), сохраняя при этом предсказания модели для каждого объекта из отложенных выборок: TS_2, TS_3, \dots, TS_K . Итого, для алгоритма $\mu(\lambda)$ имеем $\approx \frac{(K-1)T}{K}$ предсказаний для объектов на отложенных выборках⁵. Данные предсказания составляют множество $V(\mu(\lambda))$. Тогда подбор оптимального гиперпараметра λ для модели μ сводится к следующей задаче минимизации:

$$\sum_{\hat{y} \in V(\mu(\lambda))} Q(\hat{y}, y) \gamma^{T-n(y)} \rightarrow \min_{\lambda \in \Lambda} \quad (3)$$

где $\gamma \in [0, 1]$ — константа отражающая степень важности предсказаний на более актуальных данных временного ряда: $\gamma = 1 \Leftrightarrow$ стандартный алгоритм K-fold TSCV (2) — $\gamma = 0 \Leftrightarrow$ важно качество предсказания алгоритма только на последнем имеющемся наблюдении $y : n(y) = T$. Таким образом, константа γ позволяет моделям с лучшим качеством работы на актуальных данных выигрывать у моделей, показывающих себя средне на всей выборке. Таким образом, получаем обобщенную версию метода (2) — взвешенную K-fold кросс-валидацию для временных

⁴Существуют задачи, целью которых является качественное прогнозирование прошлых периодов. Например, восстановление пропущенных данных о темпе роста ВВП нынешней РФ в период советской власти

⁵ TS_1 требуется для изначального обучения модели на первой итерации (2)

рядов (K-fold WTSCV). Схожая по идее методика уже была использована в [6], однако, авторы взвешивали качество работы не по наблюдениям, а на всей отложенной выборке, т.е. множитель γ добавлялся в базовую модель кросс-валидации (2) для всей валидационной выборки на каждой из итераций.

Очевидным недостатком данного подхода является необходимость выбора оптимальной константы γ , что делает этот метод неприменимым в случае небольшого размера наблюдаемой выборки TS . Остается проверить целесообразность применения данного подхода.

2.3 Метод тестирования подхода

Проведем эксперимент на 1000 случайных рядах с месячной периодичностью, выбранных из набора M4 competition [7].

Заведем переменную $S = 0$. Для каждого ряда TS_i проведем следующую процедуру:

- Исследуемый ряд TS_i с сохранением временной структуры разбиваем в пропорции 5 к 1 на два ряда: TS_{iCV} и $TS_{i\gamma}$.
- На данных TS_{iCV} для каждого $\gamma \in [0, 0.99]$ с шагом 0.02 решаем задачу (3) при условии $\lambda \in \tilde{\Lambda} : \tilde{\Lambda} \subseteq \Lambda$. Имеем множество решений $L = \{\lambda_{\tilde{\gamma}}\}$, где $\lambda_{\tilde{\gamma}}$ — решение задачи оптимизации при $\gamma = \tilde{\gamma}$.
- После чего на участке $TS_{i\gamma}$ проверяем качество работы $q_{\tilde{\gamma}}$ полученных моделей $\mu(\lambda_{\tilde{\gamma}}) : \forall \lambda_{\tilde{\gamma}} \in L$. Записываем полученные результаты в множество $Q = \{q_{\tilde{\gamma}}\}$.
- Находим $\gamma^* : q_{\gamma^*} \leq q_{\tilde{\gamma}}, \forall q_{\tilde{\gamma}} \in Q$.
- На данных TS_{iCV} подбираем оптимальный гиперпараметр λ_1 согласно стандартной процедуре (2). Сохраняем качество работы $\mu(\lambda_1)$ на участке $TS_{i\gamma}$ в переменную q_1 .
- Обновим $S := S + [q_{\gamma^*} < q_1]$

Объектом для интереса служит отношение $\frac{S}{1000}$ (Improvement rate) — доля случаев, когда модель выбранная с помощью взвешенной кросс-валидации показала строго лучший прогноз на участке $TS_{i\gamma}$, чем модель отобранная на стандартной кросс-валидации.

Будем проверять модель на трёх разных алгоритмах используемых для прогнозирования временных рядов: Random Forest, SARIMA и Exponential Smoothing. У каждого алгоритма будем подбирать свой гиперпараметр. У RandomForest в качестве гиперпараметра будем перебирать p — кол-во лагов используемых для прогноза в периоде t , т.е. прогноз алгоритма будет иметь вид:

$$\hat{y}_t = RF(y_{t-1}, \dots, y_{t-p})$$

У SARIMA модели будем перебирать параметры p , d и q . Для ускорения эксперимента зафиксируем P , D и Q сезонные на уровне $(0, 0, 0)$. Поскольку эксперимент будет проводиться на

временных рядах с месячной периодичностью, то можем смело установить параметр сезонности $S = 12$.

Для модели ES будем перебирать всего два параметра для тренда и сезонности: аддитивность и мультипликативность. Как увидим далее, даже при столь жестких ограничениях на множество допустимых гиперпараметров модель взвешенной кросс-валидации даст заметное улучшение в сравнении со стандартным подходом.

Для измерения качества работы моделей будем использовать метрику *MAPE* (Mean Absolute Percentage Error) — средняя абсолютная ошибка в процентах.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| 100\%$$

3 Заключение

В таблице 1 приведены результаты вышеописанного эксперимента. Видим, что модифицированная версия алгоритма улучшает качество дальнейших предсказаний в среднем на 33 %. Иначе говоря, в одном из трех случаев подбор оптимального γ дает улучшение прогнозов на актуальных участках. Это говорит о том, что для получения более точных прогнозов имеет пожертвовать частью данных для подбора оптимального параметра γ , который позволит выбрать модель, которая хорошо будет предсказывать данные будущих периодов.

Модель	Improvement rate
Radnom Forest	0.214
SARIMA	0.413
Exponential Smoothing	0.373

Таблица 1: Результаты применения Weighted Time-Series Cross-Validation

Можно продолжить проверку данного подхода на других алгоритмах, однако уже видно, что даже для простых моделей взвешенный подход дает результат.

Список литературы

- [1] Zeiler Matthew D. ADADELTA: An Adaptive Learning Rate Method. 2012.
- [2] Hoerl Arthur E, Kennard Robert W. Ridge regression: Biased estimation for nonorthogonal problems // Technometrics. 1970. Т. 12, № 1. С. 55–67.
- [3] Кросс-валидация. URL: <http://neerc.ifmo.ru/wiki/index.php?title=Кросс-валидация>.
- [4] Efron Bradley. How biased is the apparent error rate of a prediction rule? // Journal of the American statistical Association. 1986. Т. 81, № 394. С. 461–470.
- [5] Gold Forward Offered Rates (GOFO). URL: <https://www.quandl.com/data/LBMA/GOFO-Gold-Forward-Offered-Rates-GOFO>.
- [6] Time series forecasting using a weighted cross-validation evolutionary artificial neural network ensemble / Juan Peralta Donate, Paulo Cortez, GermáN GutiéRrez SáNchez [и др.] // Neurocomputing. 2013. Т. 109. С. 27–32.
- [7] M4 Competition. URL: <https://www.mcompetitions.unic.ac.cy/the-dataset/>.